

DOCUMENTACIÓN

Implementación de un Modelo Predictivo Basado en Big Data para la Detección Temprana de Enfermedades en Caninos

Presentado por:

Leidy Katherine González Céspedes

Laura Jineth Suarez Ramírez

ESEIT

ESPECIALIZACIÓN EN BIG DATA Y ANALÍTICA DE DATOS

PROYECTO APLICADO II

2025

DOCUMENTACIÓN

Implementación de un Modelo Predictivo Basado en Big Data para la Detección Temprana de Enfermedades en Caninos

Introducción

El proyecto busca convertir datos clínicos de Recorvet en un modelo predictivo para la detección temprana de una enfermedad específica en animales domésticos, priorizando caninos como caso de estudio. La motivación es fortalecer la medicina preventiva, la capacidad diagnóstica y la toma de decisiones clínicas informadas.

Objetivo general

Desarrollar e implementar un modelo predictivo de una enfermedad específica en animales domésticos, usando como caso de estudio la base de datos autorizada por Recorvet.

Objetivos específicos

- Exploración y preparación: Identificar variables autorizadas, limpiar, normalizar y estandarizar datos clínicos.
- Análisis descriptivo: Reconocer prevalencias, correlaciones y patrones relevantes.
- Modelado: Entrenar y comparar algoritmos (Random Forest, PyCaret/sklearn, red neuronal con TensorFlow/Keras).
- Evaluación: Seleccionar el mejor modelo por desempeño (AUC, ROC, KS, umbral óptimo Youden J).
- Visualización: Entregar un dashboard prototipo con resumen ejecutivo, detalle clínico y tendencias.

Alcance del proyecto

Componentes incluidos

- Recolección y exploración: Filtrado de información clínica autorizada por Recorvet; limpieza y normalización.
- Análisis descriptivo: Prevalencia de enfermedad por variables independientes; correlaciones y patrones.
- Modelado predictivo: Construcción por diferentes algoritmos y selección de la alternativa con mejor AUC.

- Evaluación y ajuste: Curva ROC, matriz de confusión, KS y selección de umbral óptimo (Youden J).
- Entregables: Informes técnicos, dashboard prototipo, documentación base, presentación ejecutiva.

Componentes excluidos

- No API ni interfaz en tiempo real.
- No implementación en producción.
- Sin integración con historia clínica electrónica.
- Sin publicaciones científicas.
- Sin expansión a múltiples especies ni todas las patologías.

Visión y contribución estratégica

- Innovación tecnológica: Recorvet se posiciona en analítica predictiva aplicada al sector veterinario.
- Diferenciación competitiva: Herramientas para diagnóstico preventivo elevan la propuesta de valor.
- Expansión de servicios: Datos clínicos habilitan nuevas líneas (prevención, convenios con laboratorios).
- Fidelización: Alertas tempranas fortalecen la confianza de clínicas y tutores.

Planificación del proyecto

Cronograma

- Duración: Octubre – Diciembre 2025.
- Hitos principales:
- Fase 1: Recolección, exploración y validación de datos; normalización/estandarización.
- Fase 2: Selección de especie (caninos) y mapeo/agrupación de enfermedades.
- Fase 3: Entrenamiento baseline con Random Forest y filtrado por $AUC \geq 0,7$.

- Fase 4: Benchmarking con PyCaret/sklearn, tuning y red neuronal (SMOTE/TomekLinks, z-score, early stopping).
- Fase 5: Evaluación final (AUC, ROC, KS, Youden J) y selección del modelo óptimo.
- Fase 6: Desarrollo de dashboard prototipo y documentación.

Recursos

- Equipo: Leidy Katherine González y Laura Jineth Suárez.
- Herramientas:
- Librerías y stack: pandas, numpy, scikit-learn, PyCaret, TensorFlow/Keras, imblearn (SMOTE/TomekLinks), seaborn/matplotlib/plotly, missingno.
- Procesos auxiliares: Mapeo de enfermedades, diccionario de razas, normalización de pronósticos, variables temporales (día del año/mes).

Presupuesto y ROI

- Presupuesto: Ajustado por variación de alcance debido a ausencia de variables solicitadas (edad, sexo, peso, ciudad).
- ROI estimado (cualitativo):
- Económicos: Nuevos servicios predictivos; optimización de insumos; atracción de nuevas clínicas.
- Sociales: Bienestar animal; reducción de carga emocional y económica por diagnósticos tardíos.
- Competitivos: Liderazgo en análisis de datos aplicado al sector veterinario.

Metodología

Procesos de datos

- Limpieza y normalización:
- Texto: Función de normalización con regex; remoción de caracteres especiales; manejo de espacios y acentos.
- Extracción canónica: Clasificación de especie y raza a partir de la columna “nombre”, con reglas específicas para razas caninas y razas felinas; descarte de entradas irrelevantes.
- Estandarización clínica:

- Mapeo de diagnósticos: Diccionario robusto con agrupación clínica (Distemper, Parvovirus, Ehrlichia/Anaplasma, GI, dermatología, otitis, urinario/renal, endocrino, oncológico, neurológico, trauma, estados no diagnósticos).
- Pronóstico: Normalización a categorías: FAVORABLE, RESERVADO, DESFAVORABLE/MALO, PENDIENTE/EVALUACIÓN.
- Variables derivadas:
- Temporales: Día del año y mes para análisis de estacionalidad.
- Codificación categórica: Razas caninas con códigos categóricos y diccionario JSON exportado.

Modelado y evaluación

- Entrenamiento baseline: Random Forest por enfermedad; cálculo de AUC y selección de patologías con $AUC \geq 0,7$.
- Optimización:
- PyCaret/sklearn: setup con k-fold (10), SMOTE, outliers (iForest), normalización z-score, multicolinealidad y feature selection; compare_models, tune_model; gráficos de AUC y importancia de variables.
- Red neuronal (TensorFlow/Keras): Capas densas con GaussianNoise/GaussianDropout; balanceo (SMOTE/TomekLinks); escalado estándar; early stopping (PRC); selección por mayor AUC.
- Métricas y selección final:
- Criterios: AUC (ROC), KS, matriz de confusión y umbral óptimo (Youden J); comparación NN vs sklearn y elección del mejor.
- Salida: Guardado del modelo óptimo y del escalador (en caso NN); función de predicción para ambos enfoques.

Visualización y prototipo de dashboard

- Resumen ejecutivo: Top de enfermedades por frecuencia; desempeño del modelo; distribución de riesgo.
- Detalle clínico: Ficha por paciente (raza, fecha, enfermedad agrupada, pronóstico normalizado); probabilidad/umbral y recomendaciones.
- Tendencias: Estacionalidad por mes; series por enfermedad; distribución por razas.

Roles y responsabilidades

- Dirección técnica y analítica: Diseño de mapeos clínicos, normalización y estrategias de modelado; consolidación de métricas y selección del modelo final.
- Ingeniería de datos y visualización: Limpieza, codificación y generación de variables; construcción del dashboard prototipo y reportes ejecutivos.
- Gestión y coordinación: Relación con Recorvet, control de cambios, actualización de cronograma, riesgos y presupuesto; documentación y presentación.

Avances, resultados y control de calidad

Cumplimiento del plan de calidad

- Nombre: Modelo Predictivo Basado en Big Data para la Detección Temprana de Enfermedades en Caninos.
- Objetivo del plan: Garantizar la confiabilidad del modelo, integridad de los datos y claridad de entregables, cumpliendo estándares técnicos y funcionales.
- Ejecución: Se completó la recolección, exploración, normalización y estandarización, construcción de variables derivadas, modelado baseline y optimización; se ajustó la planificación ante la ausencia de variables adicionales.

Resultados clave

- Clasificación por enfermedad: Random Forest baseline por patología; selección de candidatas con $AUC \geq 0,7$.
- Optimización comparativa: PyCaret/sklearn vs NN; normalización y balanceo; selección final basada en AUC superior y métricas complementarias.
- Estacionalidad: Identificación de patrones temporales (mes/día del año) para campañas preventivas y planificación.
- Pronóstico: Distribución de pronósticos normalizados en casos positivos, útil para lectura de severidad.

Entregables

- Código Python: Limpieza, mapeos clínicos, creación de variables, entrenamiento baseline, optimización, evaluación y funciones de predicción.
- Diccionario de raza: Exportado en JSON para trazabilidad y uso operativo.

- Dashboard prototipo: Resumen ejecutivo, ficha clínica y tendencias poblacionales.
- Documentación técnica: Este documento y presentación ejecutiva para stakeholders.

Conclusiones y lecciones aprendidas

Conclusiones

- Valor clínico y operativo: Con datos limitados, el modelo logra discriminar riesgos para patologías seleccionadas ($AUC \geq 0,7$), habilitando acciones preventivas y soporte al triage.
- Importancia de la estandarización: La normalización de diagnósticos y pronósticos fue decisiva para coherencia analítica y desempeño.
- Madurez del prototipo: Aunque no está en producción, sienta bases sólidas para integración futura (API, HCE, monitoreo).

Limitaciones

- Variables faltantes: Edad, sexo, peso y ciudad no fueron entregadas; su ausencia limita sensibilidad y personalización.
- Alcance restringido: Prototipo académico, sin interfaz ni despliegue productivo; foco en caninos y enfermedades agrupadas.

Lecciones y mejoras futuras

- Datos adicionales: Incorporar edad, sexo, peso, ciudad, vacunación/desparasitación, laboratorio, imágenes y signos vitales.
- Operación: Desplegar API segura; integración con HCE; monitoreo de drift y recalibración de umbrales por clínica.
- Expansión: Otras especies y patologías; ajuste de modelos a contextos locales; auditoría continua de sesgos (raza, zona).
- Ciclo de vida: Retraining trimestral o tras cambios sustantivos; control de calidad continuo (AUC, sensibilidad, especificidad, KS, FPR/FNR).

- Comunicación: Alinea a equipo y stakeholders con una visión clara, técnica y accionable.
- Toma de decisiones: Sirve de referencia para priorización clínica, inversión tecnológica y rutas de integración.
- Evaluación y auditoría: Facilita revisión de procesos, métricas y trazabilidad del modelo.
- Transferencia de conocimiento: Estándares, mapeos y metodologías quedan documentados para futuros equipos y generaciones.

Anexos operativos

Buenas prácticas de actualización

- Estandarización continua: Mantener consistencia en registro clínico para mejorar el mapeo y reducir ruido.
- Retraining programado: Actualizar modelos cada trimestre o cuando se incorporen nuevas fuentes/variables.
- Monitoreo: Vigilar AUC, sensibilidad, especificidad, KS y FPR/FNR por patología; evaluar drift y reequilibrio.
- Auditoría de sesgos: Revisar distribución por razas, zonas y clínicas; ajustar umbrales y políticas de uso.

Guía de uso del dashboard (prototipo)

- Resumen ejecutivo: Revisar top de enfermedades, desempeño y distribución de riesgo para decisiones macro.
- Detalle clínico: Usar probabilidad y categoría de riesgo como apoyo a triage y definición de complementarios; no sustituye juicio clínico.
- Tendencias: Programar campañas preventivas y gestionar inventarios según estacionalidad y patrones por raza.