

Informe comparativo
Planificado vs. Ejecutado
Implementación de un Modelo Predictivo Basado en Big Data para la Detección
Temprana de Enfermedades en Caninos

Presentado por:
Leidy Katherine González Céspedes
Laura Jineth Suarez Ramírez

ESEIT
ESPECIALIZACIÓN EN BIG DATA Y ANALÍTICA DE DATOS
PROYECTO APLICADO II
2025

Informe comparativo

Planificado vs. Ejecutado

Implementación de un Modelo Predictivo Basado en Big Data para la Detección Temprana de Enfermedades en Caninos

Cumplimiento de tiempos y comparación del cronograma

Alcance temporal e hitos principales

- Periodo oficial: Octubre–Diciembre 2025.
- Fases planificadas:
- Recolección y exploración de datos.
- Análisis descriptivo.
- Desarrollo del modelo predictivo (benchmark + optimización).
- Evaluación y ajustes (AUC, ROC, KS, umbral óptimo).
- Hitos ejecutados:
- Recolección y limpieza: Estandarización y normalización clínica; extracción de especie/raza; mapeo de diagnósticos y pronóstico.
- Análisis descriptivo: Frecuencias por especie/raza; top de enfermedades; estacionalidad (día/mes).
- Modelado: Baseline Random Forest por enfermedad; selección por $AUC \geq 0,7$; optimización automatizada (PyCaret/sklearn) y NN (TensorFlow/Keras) con balanceo (SMOTE/TomekLinks).
- Evaluación: Curva ROC, matriz de confusión, KS, umbral óptimo (Youden J); consolidación de candidatos con $AUC \geq 0,7$.

Desviaciones de cronograma y causas

- Causa crítica: Falta de variables clínicas clave (edad, sexo, peso, ciudad) solicitadas en primera semana de noviembre y no entregadas hacia la tercera semana de noviembre.
- Efecto en el plan: Reprogramación de cronograma; ajustes en matriz de riesgos; revisión de presupuesto y ROI; enfocar el alcance a prototipo académico con variables disponibles.

Comparativo Gantt (planificado vs. real)

- Interpretación recomendada:
- Medir inicio/fin de cada fase; duración; holguras; impacto de dependencias (datos de Recorvet como entrada crítica).
- Destacar compresión de tiempos en modelado y evaluación para compensar el retraso de datos.

Diagrama de Gantt -Inicial





Diagrama Gantt – Final

Diagrama de Gantt - Cronograma de Proyecto



Variaciones de costos y recursos

Presupuesto

- Inicial: \$21.150.000 COP.
- Final ejecutado: \$11.850.000 COP.
- Variación: -\$9.300.000 COP (-44% vs. plan).
- Causas: Reducción de alcance (sin API/producción/HCE); optimización de tiempos/recursos por falta de nuevas variables; foco en prototipo y documentación técnica.

Asignación de recursos

- Equipo: 2 personas (Leidy Katherine González y Laura Jineth Suárez).
- Capacidades técnicas: Python (limpieza, EDA, RF); PyCaret/sklearn (benchmark y tuning); TensorFlow/Keras (NN con balanceo); visualización (matplotlib/seaborn/plotly).
- Desviaciones:
- Mayores horas en normalización clínica (diccionarios extensos, estandarización de “enfermedad” y “pronóstico”).
- Reasignación de tiempo desde integración/producción hacia evaluación y documentación.

Medidas correctivas

- Gestión de datos: Asegurar acuerdos de suministro con SLA; checklist de campos críticos; validación temprana (Data Readiness Review).
- Plan de recursos: Reservas de capacidad para limpieza avanzada; plantillas reutilizables de mapeo; automatización de benchmarking.
- Alcance adaptativo: Mantener un “MVP analítico” que entregue valor con variables disponibles; documentar requerimientos incrementales.

Escenario Moderado: Asignación 2% presupuesto inicial: \$21,150,000

Escenario Moderado: Asignación 2% presup inicial: \$21,150,000					
Año	Tasa crecimiento	Subscriptores	Asignación anual bajo(\$600.000)	Asignación anual Medio (\$1.396.000)	Asignación anual Alto (\$4.800.000)
1		250	3.000.000	6.980.000	24.000.000
2	10%	275	3.300.000	7.678.000	26.400.000
3	10%	303	3.630.000	8.445.800	29.040.000
Asignación total 3 años			9.930.000	23.103.800	79.440.000
		ROI	-53,05%	9,24%	275,60%
		Payback (años aprox)	5,83	2,50	0,88
		Payback (meses)	69,92	30,05	10,58

Escenario Moderado: Asignación 2% presupuesto Fina: \$11,850.000

Escenario Moderado: Asignación 2% presup final: \$11,850,000					
Año	Tasa crecimiento	Subscriptores	Asignación anual bajo(\$600.000)	Asignación anual Medio (\$1.396.000)	Asignación anual Alto (\$4.800.000)
1		250	3.000.000	6.980.000	24.000.000
2	10%	275	3.300.000	7.678.000	26.400.000
3	10%	303	3.630.000	8.445.800	29.040.000
Asignación total 3 años			9.930.000	23.103.800	79.440.000
		ROI	-16,20%	94,97%	570,38%
		Payback (años a	3,26	1,40	0,49
		Payback (meses	39,17	16,84	5,93

Riesgos materializados y su gestión

Riesgos observados

- Falta de variables clínicas clave: edad, sexo, peso, ciudades no entregadas a tiempo.
- Impacto: Menor capacidad explicativa/precisión; necesidad de delimitar alcance; impacto en cronograma y ROI.
- Gestión: Reprogramación del plan; foco en AUC por enfermedad; mejora del pipeline de normalización; reporte de prototipo con métricas robustas.
- Dependencia de un único origen de datos (Recorvet): Sensibilidad a retrasos y vacíos.
- Impacto: Riesgo de cuellos de botella; variabilidad en calidad de entrenamiento.
- Gestión: Documentación exhaustiva del mapeo; selección de modelos robustos a desbalance; transparencia en limitaciones.
- Alcance no productivo: Sin API/HCE/producción (por definición de alcance).
- Impacto: Valor operativo limitado; enfoque académico.
- Gestión: Dashboard prototipo; documentación clara; recomendaciones de escalamiento futuro.

Matriz de Riesgos - Proyecto Recorvet			
Predicción Temprana de Enfermedades en Animales Domésticos			
Riesgo	Nivel de Riesgo	Plan de Mitigación	Plan de Contingencia
Retraso en la entrega de información por parte de TI de Recorvet	Critico	Establecer fechas claras y recordatorios semanales para extender plazo	Ajustar cronograma y redistribuir tareas en paralelo
Calidad insuficiente de los datos clínicos de clínicos	Critico	Establecer criterios de calidad desde el inicio, Coordinar limpieza con equipo de Recorvet	Establecer modelo baseline con datos disponibles y reducir alcance del modelo
Modelo con bajo desempeño	Medio	Iteración en fases: pruebas piloto, métricas de validación y mejora continua	Ajustar hiperparámetros o cambiar algoritmo
Problemas de privacidad y seguridad de datos sensibles	Alto	Acuerdos de confidencialidad firmados, anonimización de datos, cumplimiento de normas de protección de datos	Bloquear accesos y notificar al responsable legal de Recorvet
Fallos técnicos (Hardware/Librerías)	Medio	Mantenimiento preventivo y respaldo en la nube	Uso de equipos alternativos y uso de collab como respaldo
Problemas de conectividad o energía	Medio	Copias offline y respaldo en varias redes	Reprogramar actividades y recuperar trabajo en horarios extendidos
Limitaciones técnicas del equipo	Baja	Usar herramientas ligeras y respaldar en nube	Ampliar el tiempo de ejecución

Criterios de calidad aplicados

Los criterios del plan de calidad se integraron como estándares en todo el proceso y evaluación:

- Confiabilidad del modelo: Selección por $AUC \geq 0,7$; comparación sistemática de clasificadores; evaluación de ROC, KS y umbral óptimo (Youden J).
- Integridad de datos: Limpieza de columnas irrelevantes; normalización de texto (regex, acentos, espacios); extracción canónica de especie y raza; mapeo clínico exhaustivo de “enfermedad” y “pronóstico”.
- Claridad de entregables: Reportes con métricas clave (AUC, ROC, matriz de confusión, KS); tablas de frecuencias; gráficos de estacionalidad; dashboard prototipo con resumen ejecutivo, detalle clínico y tendencias.

Aplicación práctica en la evaluación:

- Modelo baseline: Random Forest por enfermedad para ranking inicial (AUC).
- Optimización: Benchmark con PyCaret/sklearn; tuning y gráficos; NN con balanceo (SMOTE/TomekLinks), normalización z-score y early stopping.
- Selección final: Métrica principal AUC; corroboración con ROC y KS; definición de umbral operativo (Youden J).

Ejecución del ROI y análisis comparativo

Supuestos base

- Suscriptores base: 250 clínicas.
- Asignación a recuperación: 2% de cada suscripción anual.
- Tarifas anuales: Bajo \$600.000; Medio \$1.396.000; Alto \$4.800.000.
- Crecimiento moderado: 10% anual (interpretar como incremento de suscriptores o ingreso; documentar supuesto elegido en el informe).

Recuperación anual estimada (año 1)

- Escenario Bajo: $0,02 \times 250 \times 600.000 = \$3.000.000$ COP.
- Escenario Medio: $0,02 \times 250 \times 1.396.000 = \$6.980.000$ COP.
- Escenario Alto: $0,02 \times 250 \times 4.800.000 = \$24.000.000$ COP.

Payback vs. inversión ejecutada

- Inversión ejecutada: \$11.850.000 COP.
- Payback (año 1, sin crecimiento):
- Bajo: $11.850.000 / 3.000.000 \approx 3,95$ años.
- Medio: $11.850.000 / 6.980.000 \approx 1,70$ años.
- Alto: $11.850.000 / 24.000.000 \approx 0,49$ años.

Notas para comparación plan vs. ejecución

- Plan inicial: Inversión \$21.150.000 COP. La reducción a \$11.850.000 mejora el payback en todos los escenarios.
- Sensibilidades clave: Entrega de variables clínicas; escalamiento a API/HCE; segmentación de tarifas; adopción por clínicas.

Lecciones aprendidas, buenas prácticas y recomendaciones

Lecciones aprendidas

- ❖ Disponibilidad de datos es el cuello de botella principal: Formalizar acuerdos de entrega con SLA, validación temprana y checklist de campos críticos evita reprogramaciones.
- ❖ Normalización clínica extensa agrega valor: Diccionarios y mapeos estandarizan el análisis y elevan la calidad del modelo aun con variables limitadas.
- ❖ Benchmarking automatizado acelera decisiones técnicas: Comparar múltiples algoritmos (sklearn/PyCaret) y NN con balanceo mejora robustez y trazabilidad.
- ❖ Buenas prácticas
- ❖ Pipeline de datos replicable: Funciones de limpieza y extracción (regex, acentos, espacios, especie/raza), mapeos clínicos versionados, control de pronóstico normalizado.
- ❖ Evaluación con múltiples métricas: AUC como métrica principal; ROC y KS para separabilidad; umbral Youden J para operación.
- ❖ Dashboard para decisiones: Resumen ejecutivo; detalle por paciente; tendencias poblacionales y estacionales; soporte a triage preventivo.
- ❖ Recomendaciones para futuros proyectos
- ❖ Incrementar variables clínicas: Edad, sexo, peso, ciudad, vacunación, desparasitación, antecedentes, laboratorio, signos vitales, imágenes.
- ❖ Despliegue seguro: API con autenticación y monitoreo; integración con HCE; gobierno de datos y auditoría.
- ❖ Estrategia de producto: Reunir valor analítico (alertas tempranas, planes de prevención, convenios con laboratorios); pricing y segmentación por clínica.
- ❖ Monitoreo continuo: Retrain trimestral/post-cambios; métricas por enfermedad y por clínica (sensibilidad, especificidad, FPR/FNR); auditoría de sesgos (raza, zona).

Conclusiones

Valor generado con el proyecto

El proyecto entregó un prototipo predictivo robusto y trazable, capaz de identificar patrones clínicos relevantes en caninos mediante algoritmos de aprendizaje automático. Se logró una normalización exhaustiva de datos clínicos (especie, raza, diagnósticos y pronósticos), garantizando coherencia analítica. El modelo fue evaluado con múltiples métricas de desempeño (AUC, ROC, KS, matriz de confusión, umbral Youden J), alcanzando valores superiores a 0,7 en enfermedades seleccionadas. Este resultado constituye un activo estratégico para la medicina preventiva veterinaria, aportando herramientas de gestión clínica que optimizan procesos diagnósticos y fortalecen la propuesta de valor de Recorvet.

Brecha vs. producción

A pesar de los avances, el impacto productivo inmediato se ve limitado por:

- Falta de variables clínicas críticas (edad, sexo, peso, ciudad), que restringen la capacidad explicativa y la precisión del modelo.
- Ausencia de despliegue operativo (API, integración con historia clínica electrónica, monitoreo en producción), lo que impide la adopción masiva en entornos clínicos reales.
- Alcance académico/prototipo, sin mecanismos de escalamiento ni validación en escenarios de uso continuo.

Decisiones recomendadas

1. Formalizar el suministro de datos y ampliar variables clínicas:
 - Establecer acuerdos con Recorvet para garantizar entrega periódica y completa de información.
 - Incorporar variables adicionales (signos vitales, resultados de laboratorio, antecedentes médicos, vacunación) para mejorar la sensibilidad y especificidad del modelo.
2. Planificar fase de integración segura y monitoreo:
 - Diseñar una API con autenticación y trazabilidad, que permita consultas en tiempo real.
 - Integrar el modelo con sistemas de historia clínica electrónica (HCE) bajo protocolos de seguridad y confidencialidad.
 - Implementar un esquema de monitoreo continuo y retrain trimestral, asegurando que el modelo se mantenga actualizado frente a nuevas tendencias clínicas.
3. Ejecutar estrategia de monetización ajustada por segmento:

- Definir planes de suscripción diferenciados para clínicas pequeñas, medianas y grandes, con tarifas escalonadas.
- Ofrecer servicios premium como alertas tempranas, dashboards personalizados y convenios con laboratorios veterinarios.
- Realizar un seguimiento del ROI con escenarios de recuperación (bajo, medio, alto) y ajustar la estrategia comercial según la adopción real.